

Compte rendu semaine 7

Projet sciences des Données 4
L3 MIAHS — Chloé, Sarah, Hafsa, Nadir

Répartition des tâches

Chloé	Modèle Bag of Words + Régression logistique
Sarah	Modèle TF-IDF + Régression logistique
Hafsa	Modèle Random Forest
Nadir	Modèle Régression logistique et Toxic BERT

Semaine 7 — Entraînement et évaluation des modèles d'IA

Chloé, Sarah et Hafsa étaient présentes cette semaine. Nadir, absent ce jour-là, a contribué à distance.

À partir des visualisations réalisées en semaine 6, on a conclu qu'il était pertinent de travailler sur cinq modèles de prédiction : la Régression logistique, TF-IDF avec Régression logistique, Bag of Words avec Régression logistique, Random Forest et Toxic BERT. Chaque membre du groupe a pris en charge un ou plusieurs modèles de façon autonome.

Nous disposons de deux bases de données : une base d'entraînement représentant 80% des données et une base de test représentant les 20% restants. Les modèles ont été entraînés plusieurs fois sur la base d'entraînement afin d'optimiser leurs performances, en ajustant les paramètres lorsque cela était nécessaire. Une fois entraînés, ils ont été évalués sur la base de test composée de données inédites pour garantir une évaluation objective.

Après comparaison des résultats, les modèles TF-IDF et Toxic BERT se sont révélés les plus performants.

Pour la semaine 8

- Améliorer et finaliser le notebook existant
- Ajouter un code permettant la prédiction par catégories
- Poursuivre l'optimisation globale du projet
- Commencer le développement du site web vitrine