

Université Paul-Valéry Montpellier 3

Licence 3 MIASHS — UE Science des Données 4

SafeText

Détection automatique du harcèlement en ligne

Rapport de projet

« Chaque jour, des millions de personnes subissent des violences verbales en ligne. SafeText est un outil d'intelligence artificielle conçu pour détecter, comprendre et nommer ces formes de haine — afin de les rendre visibles. »

Équipe projet

Nom	Numéro étudiant
Chloé RIBAUT	22302048
Sarah OUKNINE	22302931
Nadir DABDOUBI	22410789
Hafsa ACHLOUAOU	22300133

Encadré par

Sandra BRINGAY, Namrata PATEL, Théodore MICHEL-PICQUÉ

Année universitaire 2025–2026 | Rendu le 12 avril 2026

Table des matières

1	Introduction	4
1.1	Contexte et motivation	4
1.2	Problématique et objectifs	4
1.3	Présentation de l'équipe	5
2	Organisation et gestion de projet	7
2.1	Vue d'ensemble du planning	7
2.2	Répartition des tâches	9
2.2.1	Contribution par tâches	9
2.2.2	Contribution par pages du site web	10
2.3	Personas utilisateurs	11
2.3.1	Persona 1	11
2.3.2	Persona 2	12
2.4	Suivi Git et organisation du dépôt	13
2.4.1	Backlog et Storymap	13
2.5	Maquette Figma	14
3	Données	16
3.1	Constitution de la base de données	16
3.2	Modèle Conceptuel de Données (MCD) et Modèle Physique (M0D)	17
3.3	Schéma SQL	18
3.4	La confusion initiale sur les bases train/test	19
3.5	Structure finale des données	20
3.6	Preprocessing et nettoyage	21
4	Analyse exploratoire des données	22
4.1	Objectifs de l'analyse exploratoire des données et lien avec la modélisation	22
4.2	Structure et équilibre des données	23
4.3	Analyse linguistique	23
4.4	Analyse stylistique ; longueur, ponctuation et agressivité	25
4.4.1	Longueur des messages	25
4.4.2	Ponctuation et majuscules	26
4.5	Analyse émotionnelle — lexique NRC	26

4.6	Nuages de mots	27
4.7	Ce que l' analyse exploratoire des données nous a appris	29
5	Modélisation Machine Learning	30
5.1	Stratégie de modélisation, pourquoi cette progression ?	30
5.2	Modèle 1 — Régression Logistique	31
5.2.1	Justification du choix	31
5.2.2	Paramètres du modèle	31
5.2.3	Résultats	31
5.3	Modèle 2 — TF-IDF + Régression Logistique	32
5.3.1	Justification du choix	32
5.3.2	Paramètres du modèle	32
5.3.3	Résultats	32
5.4	Modèle 3 — Bag of Words + Régression Logistique	33
5.4.1	Justification du choix	33
5.4.2	Démarche d'entraînement progressif	33
5.4.3	Résultats	34
5.5	Modèle 4 — Random Forest	34
5.5.1	Justification du choix	34
5.5.2	Paramètres du modèle	34
5.5.3	Résultats	35
5.6	Modèle 5 — Toxic BERT	35
5.6.1	Justification du choix	35
5.6.2	Résultats	35
5.7	Comparaison des modèles, tableau récapitulatif	36
5.8	Limites identifiées	37
6	Application web : SafeText	38
6.1	Objectifs et conception	38
6.2	Fonctionnalités développées	39
6.2.1	Page d'accueil — <code>index.php</code>	39
6.2.2	Prédiction — <code>predict.py</code>	39
6.2.3	Comparaison des modèles — <code>comparer.py</code>	39
6.2.4	Traducteur — <code>traducteur.py</code>	39
6.2.5	Page Prévention — <code>prevention.php</code>	40
6.2.6	Quiz — <code>quiz.php</code>	40
6.2.7	Espace compte — <code>compte.php</code>	40
6.3	Architecture technique	40

6.3.1	Stack technologique	40
6.3.2	Intégration des modèles .pkl	40
6.3.3	Déploiement sur IONOS	41
6.4	Visualisations intégrées au site	43
7	Conclusion	44
7.1	Bilan du projet	44
7.2	Limites et pistes d'amélioration	45
7.3	Ce que le projet nous a apporté	46

Chapitre 1

Introduction

1.1 Contexte et motivation

Le numérique a profondément transformé nos façons de communiquer, de nous informer et d'interagir. Mais cette révolution s'accompagne d'un phénomène préoccupant : la multiplication des discours haineux en ligne. Insultes, menaces, propos discriminatoires — ces formes de violence verbale touchent des millions de personnes chaque jour, sur les réseaux sociaux, dans les espaces de commentaires, dans les messageries instantanées.

Quelques chiffres clés

- **1 Français sur 3** a déjà été victime de cyberharcèlement
- **78 %** des victimes ne portent jamais plainte
- **40 %** des contenus haineux signalés concernent le racisme et la xénophobie
- Les peines encourues pour incitation à la haine en ligne peuvent atteindre **3 ans** d'emprisonnement en France

Face à cette réalité, la détection automatique des discours haineux est devenue un enjeu majeur pour les plateformes numériques, les associations de protection des victimes et les institutions. Mais détecter la haine en ligne n'est pas trivial : elle prend des formes multiples, s'exprime dans des registres variés, et peut être explicite comme profondément dissimulée derrière un vocabulaire apparemment neutre.

C'est dans ce contexte que s'inscrit notre projet **SafeText** : construire un système d'intelligence artificielle capable de détecter automatiquement si un message est haineux, puis d'identifier à quelle forme de haine il appartient parmi six catégories ciblées.

1.2 Problématique et objectifs

Notre projet répond à une double problématique :

1. **Peut-on détecter automatiquement un message haineux ?** C'est la tâche dite *binaires* : distinguer les messages haineux des messages neutres.

2. **Peut-on identifier la forme de haine ?** C'est la tâche *multi-classes* : classifier un message parmi six catégories de discours haineux.

Les six catégories que nous avons retenues sont les suivantes :

N°	Catégorie	Description
1	Homophobie	Discriminations envers les personnes LGBTQ+
2	Islamophobie	Haine envers les musulmans ou l'islam
3	Racisme	Discriminations fondées sur l'origine ou la couleur de peau
4	Sexisme	Discriminations fondées sur le genre
5	Validisme	Discriminations envers les personnes en situation de handicap
6	Xénophobie	Haine envers les étrangers ou les immigrés

Pour répondre à cette problématique, nous nous sommes fixé plusieurs objectifs :

- Constituer et analyser une base de données de messages haineux et neutres
- Produire une analyse exploratoire approfondie pour comprendre nos données avant toute modélisation
- Entraîner et comparer plusieurs modèles de machine learning, du plus classique au plus avancé
- Déployer ces modèles sur un site web interactif, accessible à tous
- Proposer des fonctionnalités originales qui vont au-delà de la simple détection

1.3 Présentation de l'équipe

Ce projet a été réalisé dans le cadre de l'UE Science des Données 4 de la Licence 3 MIASHS à l'Université Paul-Valéry Montpellier 3, sous la direction de Sandra BRINGAY, Namrata PATEL et Théodore MICHEL-PICQUÉ.

Membre	N° étudiant	Contributions principales
Chloé RIBAUT	22302048	Modélisation ML, site web, coordination
Sarah OUKNINE	22302931	Analyse exploratoire, visualisations, rapport
Nadir DABDOUBI	22410789	Base de données, modèles conceptuels, Figma
Hafsa ACHLOUAOU	22300133	Preprocessing, notebook, comptes rendus

Lien vers le projet

- **Site web** : <http://217.160.27.219>
- **Dépôt GitHub** : <https://github.com/hafsaac/Harcelement>
- **Lien vidéo Youtube** : https://youtu.be/g_RdN-bG95w

Chapitre 2

Organisation et gestion de projet

2.1 Vue d'ensemble du planning

Le diagramme de Gantt ci-dessous présente la chronologie complète du projet SafeText sur les huit semaines de travail. Il illustre la progression parallèle des différents axes du projet : constitution de la base de données, analyse exploratoire, modélisation machine learning, développement du site web et rédaction du rapport final.



FIGURE 2.1 – Diagramme de Gantt — Projet SafeText (Semaines 1 à 8)

ÉTAPES



BASE DE DONNÉES

- Constitution bases de données → Collecte et sélection des jeux de données sur Kaggle, nettoyage et tri des données brutes, création des bases d'entraînement et de test
- Modèles conceptuels → Conception du modèle conceptuel et organisationnel des données, création du fichier SQL, structuration de la base
- Rééquilibrage et correction base → Correction de la confusion train/test, création de la base Harcèlement unifiée, équilibrage à 200 textes par catégorie

ANALYSE EXPLORATOIRE

- Compréhension et analyse de nos données → Exploration statistique de la distribution des classes, identification des déséquilibres et des caractéristiques linguistiques par catégorie
- Visualisations → Création de nuages de mots, graphiques de distribution et analyses de fréquences pour orienter le choix des modèles
- Refonte des visualisations → Reprise complète des visualisations sur la base Harcèlement unifiée pour garantir des résultats fiables

MODÉLISATION (ML)

- Code et entraînement notebook → Développement du pipeline de preprocessing NLP, vectorisation et premiers entraînements
- Recherche et choix des modèles → Sélection de cinq approches : Régression Logistique, TF-IDF, Bag of Words, Random Forest et Toxic BERT
- Évaluation et comparaison des modèles → Calcul des métriques (F1-score, précision, rappel, matrice de confusion) et comparaison des performances
- Sauvegarde .pkl → Export des modèles entraînés au format pickle pour intégration dans le site web

CONCEPTION SITE WEB

- Développement Full Stack → Développement des pages PHP et scripts Python, intégration des modèles .pkl, création du formulaire de prédiction
- Déploiement IONOS → Mise en ligne du site, configuration du serveur et tests de fonctionnement en production

RAPPORT FINAL

- Nettoyage du dépôt GitHub → Restructuration des dossiers (src/, docs/, archives/), homogénéisation du nommage, rédaction du README
- Rédaction du rapport final → Rédaction complète en LaTeX sur Overleaf, intégration des graphiques et analyses
- Vidéo présentation du rapport → Enregistrement de la vidéo de soutenance avec intervention de chaque membre
- Préparation soutenance orale → Préparation des réponses aux questions sur les choix méthodologiques et les modèles

FIGURE 2.2 – Détail des étapes par phase du projet

2.2 Répartition des tâches

2.2.1 Contribution par tâches

Le tableau suivant présente la répartition du travail entre les quatre membres du groupe sur l'ensemble des tâches du projet.

Répartition des tâches par membre				
Tâche	Chloé	Sarah	Nadir	Hafsa
Constitution base de données	10 %	40 %	10 %	40 %
Analyse exploratoire	40 %	20 %	20 %	20 %
MCD/MOD/SQL	10 %	10 %	50 %	30 %
Maquette Figma & Personas	35 %	25 %	25 %	15 %
Modélisation ML	20 %	20 %	40 %	20 %
Site web	40 %	25 %	25 %	10 %
Comptes rendus	30 %	50 %	10 %	10 %
Rapport final	25 %	25 %	25 %	25 %

FIGURE 2.3 – Répartition des tâches par membre

2.2.2 Contribution par pages du site web

Le tableau ci-dessous précise la contribution de chaque membre sur chaque fichier du site web.




FIGURE 2.4 – Répartition des pages du site web par membre

2.3 Personas utilisateurs

Afin de mieux cerner les besoins auxquels SafeText doit répondre, nous avons défini deux personas représentatifs de nos utilisateurs cibles. Cette démarche nous a permis d’orienter les choix fonctionnels du site web : simplicité d’usage pour le grand public, et capacité de classification fine pour les professionnels.

2.3.1 Persona 1



Léa

AGE: 19 ans
GENRE : Femme
NIVEAU TECH : Débutant / intermédiaire
SITUATION: Étudiante, très active sur les réseaux sociaux
RÉSEAUX UTILISÉS : Instagram, TikTok, Twitter

PROBLÈME : Reçoit régulièrement des messages hostiles sans savoir si c'est du vrai harcèlement
BESOIN : Un outil simple pour analyser un message et savoir si elle doit le signaler
CITATION : "Je ne sais jamais si je suis trop sensible ou si c'est vraiment du harcèlement"

FIGURE 2.5 – Persona 1 — Léa, 19 ans, étudiante

Léa représente l'utilisatrice type qui subit des violences verbales en ligne sans toujours savoir les identifier. SafeText lui offre un outil simple, accessible et immédiat pour analyser un message et décider si elle doit le signaler.

2.3.2 Persona 2



Thomas

AGE: 34 ans
GENRE : Homme
NIVEAU TECH : Avancé
SITUATION: Community manager dans une entreprise tech
RÉSEAUX UTILISÉS : Toutes plateformes professionnelles

PROBLÈME : Doit traiter des centaines de signalements par jour, manque d'outils automatisés
BESOIN : Un système capable de pré-classifier les messages haineux par catégorie
CITATION : "J'ai besoin de savoir rapidement si un message est problématique et de quelle nature"

FIGURE 2.6 – Persona 2 — Thomas, 34 ans, community manager

Thomas représente le professionnel de la modération en ligne, confronté quotidiennement à un volume massif de signalements. SafeText lui apporte une classification automatique par catégorie de haine, réduisant le temps de traitement et améliorant la précision des décisions de modération.

2.4 Suivi Git et organisation du dépôt

Le projet a été entièrement versionné sur GitHub, ce qui nous a permis de travailler en parallèle sans conflits et de garder une trace de chaque évolution du code et des données.

Dépôt GitHub

<https://github.com/hafsaac/Harcelement>

L'organisation du dépôt respecte une structure claire :


- **Site web/** — Code source du site web (PHP, Python, CSS) + quelques fichiers .pkl (hormis Toxic Bert car trop volumineux pour GitHub)
- **Modeles conceptuels/** — MCD/MPD
- **Archives/** — Anciennes versions et fichiers de travail
- **Bases de données/** — Fichiers SQL et CSV
- **Code/** — Notebook Jupyter de modélisation ML
- **Compte rendu/** — Intégralité des comptes rendus semaine 1 à 8
- **Visualisations/** — Visualisations faites sur R (Analyse exploratoire de données)
- **Video/** — Lien de la vidéo Youtube de présentation du projet

Chaque membre a contribué de manière équivalente via des commits réguliers tout au long des huit semaines. Le dépôt a fait l'objet d'un nettoyage complet en semaine 8 : suppression des fichiers redondants ou anciens, restructuration/organisation des dossiers, homogénéisation du nommage et rédaction d'un README professionnel présentant le projet, les données, les objectifs et les technologies utilisées.

2.4.1 Backlog et Storymap

La gestion des tâches du projet a été organisée via GitHub Projects, en suivant une méthodologie agile. Nous avons constitué une Storymap regroupant l'ensemble des user stories du projet, rédigées sous la forme « *En tant que visiteur, je veux...* ».

Au total, 39 user stories ont été complétées (**Done**), couvrant l'ensemble des fonctionnalités du site : analyse de messages, visualisations, quiz, traducteur et espace compte. Le backlog a été organisé en quatre colonnes : *Ready*, *In progress*, *In review* et *Done*.



The screenshot shows a GitHub Backlog for the project 'Storymap - Harcelement'. The interface includes a search bar, navigation tabs (Backlog, Priority board, Team items, Roadmap, My items, View 6, + New view), and a 'View' button. The backlog table lists 14 tasks, all assigned to 'nadir499' or 'erbit', with a status of 'Done'. The tasks are numbered 1 through 14, and the last item is partially visible as '15'.

Title	Assignees	Status	Linked pull requests	Sub-issues progress
1 En tant que visiteur, je veux voir les chiffres clés du dataset (2 640 messages, 50/50, 6 ...	nadir499	Done		
2 En tant que visiteur, je veux voir le usage de mots comparatif haineux vs non haineux aff...	nadir499	Done		
3 En tant que visiteur, je veux voir le top 10 des mots par catégorie afin d'identifier les mar...	nadir499	Done		
4 En tant que visiteur, je veux lire pour chaque visualisation un encart 'Ce que ça nous a a...	nadir499	Done		
5 En tant que visiteur, je veux voir le profil émotionnel NRC par catégorie afin de comprend...	nadir499	Done		
6 En tant que visiteur, je veux accéder à un lien vers la page d'analyse depuis la conclusio...	nadir499	Done		
7 En tant que visiteur, je veux coller ou saisir un message dans le champ de texte afin de l...	nadir499	Done		
8 En tant que visiteur, je veux voir le compteur de messages analysés se mettre à jour en t...	nadir499	Done		
9 En tant que visiteur, je veux voir un thermomètre de toxicité animé après l'analyse afin d...	nadir499	Done		
10 En tant que visiteur, je veux voir la catégorie de harcèlement détectée (homophobie, raci...	erbit	Done		
11 En tant que visiteur, je veux pouvoir activer le mode pédagogique afin de voir quels mots...	erbit	Done		
12 En tant que visiteur, je veux pouvoir comparer les résultats entre plusieurs modèles (BER...	erbit	Done		
13 En tant que visiteur, je veux voir des ressources d'aide (numéros, associations) affichées...	erbit	Done		
14 En tant que visiteur, je veux soumettre un message avec Ctrl+Entrée afin d'accélérer mo...	erbit	Done		
15 En tant que visiteur, je veux voir les performances des modèles (barres animées) afin d...	erbit	Done		

FIGURE 2.7 – Capture d’écran du Backlog GitHub

2.5 Maquette Figma

Avant le développement du site web, une maquette interactive a été réalisée sur Figma afin de définir l’identité visuelle et l’architecture des pages de SafeText. Cette étape nous a permis de valider les choix de design (couleurs, typographie, disposition des éléments) avant d’écrire la moindre ligne de code.



FIGURE 2.8 – Maquette Figma de la future page prévention

Chapitre 3

Données

3.1 Constitution de la base de données

La première étape du projet a consisté à constituer une base de données solide et équilibrée, capable de soutenir un apprentissage automatique fiable. Le choix du sujet : la détection du harcèlement en ligne impliquait de travailler sur des données textuelles annotées, c'est-à-dire des messages déjà étiquetés comme haineux ou non haineux.

Après exploration de plusieurs sources publiques, deux jeux de données disponibles sur la plateforme Kaggle ont été retenus :

- **Linguistic Analysis of Hateful Speech Dataset** : un corpus de messages annotés selon plusieurs formes de discours haineux, couvrant le racisme, le sexisme, l'homophobie et d'autres catégories discriminatoires.
- **YouTube Toxicity Data** : un ensemble de commentaires issus de YouTube, annotés selon leur degré de toxicité et leur nature (insultes, menaces, haine ciblée, etc.).

Ces deux sources ont été choisies pour leur complémentarité : l'une couvre des formes de haine explicites et catégorisées, l'autre apporte une diversité stylistique et contextuelle propre aux espaces de commentaires vidéo. Leur combinaison nous a permis de construire une base plus robuste et plus représentative de la réalité du harcèlement en ligne.

3.2 Modèle Conceptuel de Données (MCD) et Modèle Physique (MOD)

Avant de construire la base de données SQL, nous avons modélisé la structure de nos données à travers un Modèle Conceptuel de Données (MCD).

Le MCD nous a permis d'identifier les entités principales : les messages textuels, leurs étiquettes (type et catégorie), et leur appartenance à l'ensemble d'entraînement ou de test.

Note sur les versions

Le MCD et le MOD ont été révisés à deux reprises au cours du projet : une première version a été produite en semaine 2, puis corrigée en semaine 3 suite au rééquilibrage des données, et à nouveau mise à jour en semaine 5 après la refonte complète de la base de données.




FIGURE 3.1 – Notre MCD final

3.3 Schéma SQL

La base de données a été implémentée en SQL dans un fichier `harcelement.sql`. Elle repose sur une structure simple et efficace : une table principale contenant l'ensemble des messages, avec les colonnes suivantes :

Colonne	Type	Description
<code>id</code>	INTEGER	Identifiant unique du message
<code>texte</code>	TEXT	Contenu brut du message
<code>traduction</code>	TEXT	Traduction française du message
<code>type</code>	VARCHAR	Haineux ou Non Haineux
<code>categorie</code>	VARCHAR	Catégorie de harcèlement (si haineux)

La colonne `type` permet la classification binaire ; la colonne `categorie` permet la classification multi-classes parmi les six formes de harcèlement retenues.

harcelement base_test	harcelement base_train
Identifiant : int(3)	Identifiant : int(4)
Texte : varchar(154)	Texte : varchar(193)
Traduction : varchar(167)	Traduction : varchar(220)
Types : varchar(11)	Types : varchar(11)
Categories : varchar(12)	Categories : varchar(12)

FIGURE 3.2 – Notre MOD final

3.4 La confusion initiale sur les bases train/test

Une erreur fructueuse

Cette section décrit une confusion méthodologique rencontrée en début de projet, sa détection et sa correction. Nous nous devons d'être transparents dessus, les erreurs font parties d'une démarche scientifique rigoureuse.

En début de projet, notre équipe a construit deux bases de données distinctes et indépendantes : une base d'entraînement et une base de test, constituées séparément à partir des sources Kaggle. Cette approche semblait intuitivement correcte ; séparer dès le départ les données d'apprentissage et d'évaluation.

Cependant, lors de la séance du mercredi 11 mars (semaine 5), notre encadrante a mis en lumière une confusion fondamentale dans cette organisation. En réalité, la séparation train/test ne doit pas être opérée au niveau de la constitution des données, mais au niveau de leur utilisation :

1. On constitue d'abord **une seule base complète** regroupant l'ensemble des messages disponibles.
2. On divise ensuite cette base en **80 % pour l'entraînement** et **20 % pour le test**, de façon aléatoire et contrôlée.

Cette distinction était cruciale : en construisant deux bases séparées manuellement, nous risquions d'introduire des biais de sélection et de rendre l'évaluation des modèles non fiable. Les visualisations réalisées jusqu'alors sur la seule base d'entraînement n'étaient donc pas représentatives de l'ensemble des données.

Correction apportée

Suite à cette discussion, l'ensemble du groupe a revu la structure des données. Une base unique appelée **base Harcèlement** a été constituée, regroupant l'intégralité des messages. Toutes les visualisations ont été refaites sur cette base complète, et la séparation train/test a été confiée aux algorithmes de machine learning via la fonction `train_test_split` de scikit-learn avec un ratio 80/20.

3.5 Structure finale des données

La base Harcèlement finale présente la structure suivante :

Catégorie	Type	Nombre de messages
Homophobie	Haineux	220
Islamophobie	Haineux	220
Racisme	Haineux	220
Sexisme	Haineux	220
Validisme	Haineux	220
Xénophobie	Haineux	220
Non haineux	Non Haineux	1320
Total		2640 messages

Cet équilibre est essentiel : avec 220 messages par catégorie haineuse et 1320 messages non haineux, aucune classe ne domine les autres. Cela évite le biais de classe : un modèle entraîné sur des données déséquilibrées aurait tendance à prédire systématiquement la classe majoritaire, gonflant artificiellement ses métriques sans réellement apprendre à distinguer les catégories.

3.6 Preprocessing et nettoyage

Avant toute modélisation, les données textuelles ont subi plusieurs étapes de nettoyage et de prétraitement :

1. **Suppression des doublons** : les messages identiques ou quasi-identiques ont été retirés pour éviter une sur-représentation artificielle.
2. **Suppression des valeurs manquantes** : toute entrée sans texte ou sans étiquette a été écartée.
3. **Filtrage des messages ambigus** : certains messages trop neutres ou trop génériques pour appartenir clairement à une catégorie ont été identifiés et retirés manuellement.
4. **Mise en minuscules** : l'ensemble du texte a été converti en minuscules pour uniformiser le vocabulaire.
5. **Suppression des stop words** : les mots vides de sens (articles, prépositions, etc.) ont été retirés à l'aide des listes de stop words anglais de la bibliothèque `nltk`.
6. **Vectorisation** : les textes ont ensuite été transformés en représentations numériques exploitables par les algorithmes de machine learning, via TF-IDF ou Bag of Words selon le modèle utilisé.

Ces étapes de preprocessing constituent le fondement de toute la chaîne de traitement NLP du projet. Leur qualité conditionne directement les performances des modèles : des données mal nettoyées produisent des modèles bruités et peu généralisables.

Chapitre 4

Analyse exploratoire des données

4.1 Objectifs de l'analyse exploratoire des données et lien avec la modélisation

Avant de construire le moindre modèle de machine learning, il est indispensable de comprendre en profondeur les données sur lesquelles il va s'entraîner. C'est précisément le rôle de l'analyse exploratoire des données : examiner, visualiser et interpréter les données pour en révéler la structure, les tendances, les anomalies et les caractéristiques discriminantes.

Dans notre projet, l'analyse exploratoire des données poursuit plusieurs objectifs concrets :

- Vérifier l'équilibre entre les classes et détecter d'éventuels biais dans la distribution des données
- Identifier les caractéristiques linguistiques propres à chaque catégorie de harcèlement
- Comprendre le vocabulaire dominant utilisé dans les messages haineux et non haineux
- Orienter le choix des modèles de machine learning les plus adaptés à nos données
- Déterminer le type de tâche de prédiction à effectuer : classification binaire, multi-classes, ou les deux

EDA et décisions de modélisation

Chaque visualisation produite a orienté une décision concrète sur la suite du projet. C'est à partir des résultats de l'analyse exploratoire des données que nous avons choisi nos cinq modèles, notre stratégie de vectorisation et notre approche d'évaluation.

4.2 Structure et équilibre des données

La première analyse porte sur la distribution des classes dans notre base Harcèlement. Un déséquilibre marqué entre les catégories constituerait un biais d'apprentissage majeur : le modèle apprendrait à prédire les classes majoritaires au détriment des classes rares.




FIGURE 4.1 – Répartition équilibrée

4.3 Analyse linguistique

L'analyse du vocabulaire dominant par catégorie constitue l'une des étapes les plus révélatrices de notre analyse exploratoire des données. En extrayant les mots les plus fréquents pour chaque type de harcèlement, nous avons pu identifier des marqueurs lexicaux : des termes récurrents et discriminants propres à chaque catégorie.

Cette analyse révèle plusieurs observations importantes :

- Chaque catégorie possède un vocabulaire spécifique et identifiable, ce qui valide la pertinence d'une approche multi-classes.
- Certains termes apparaissent dans plusieurs catégories (notamment dans le racisme et la xénophobie, qui partagent un vocabulaire partiellement commun), ce qui explique les confusions que l'on observera plus tard dans les matrices de confusion des modèles.
- Les messages non haineux présentent un vocabulaire beaucoup plus neutre et diversifié, sans termes discriminants récurrents.




FIGURE 4.2 – Vocabulaire dominant par type

4.4 Analyse stylistique ; longueur, ponctuation et agressivité

Au-delà du vocabulaire, nous avons analysé les caractéristiques stylistiques des messages pour identifier des patterns formels discriminants.

4.4.1 Longueur des messages

L'analyse de la longueur des messages (en nombre de mots et de caractères) révèle des différences notables entre les catégories :

- Les messages sexistes et homophobes tendent à être plus longs, souvent construits sous forme d'arguments ou de justifications.
- Les messages racistes et xénophobes sont souvent plus courts et directs, sous forme d'insultes ou de slogans.
- Les messages non haineux présentent une distribution de longueur plus homogène et généralement plus courte.




FIGURE 4.3 – Longueur moyenne des messages par catégorie

4.4.2 Ponctuation et majuscules

L’usage intensif de majuscules et de points d’exclamation est un indicateur fort d’agressivité dans le texte. Notre analyse montre que les messages haineux présentent en moyenne un taux de majuscules et de ponctuation agressive significativement plus élevé que les messages neutres.





FIGURE 4.4 – Score d’agressivité stylistique par catégorie

4.5 Analyse émotionnelle — lexique NRC

Pour aller au-delà de la simple analyse de fréquence, nous avons utilisé le **lexique NRC** (*NRC Word Emotion Association Lexicon*), une ressource associant des mots à des émotions primaires : colère, peur, tristesse, dégoût, anticipation, confiance, surprise et joie.

Cette analyse émotionnelle nous a permis de quantifier le registre émotionnel dominant dans chaque catégorie de harcèlement :

- La **colère** et le **dégoût** dominent très nettement dans l’ensemble des messages haineux, toutes catégories confondues.
- La **peur** est particulièrement présente dans les messages islamophobes et xénophobes, souvent construits autour d’un discours de menace ou d’invasion.
- Les messages sexistes mobilisent davantage le **dégoût** et le **mépris**.
- Les messages non haineux présentent une distribution émotionnelle plus équilibrée, avec une légère dominance de la **confiance** et de la **joie**.



Lecture du graphique : Chaque catégorie présente une **signature émotionnelle distincte** : la colère domine dans l'Islamophobie et le Sexisme, la tristesse ressort dans le Racisme, la peur carac-

17

FIGURE 4.5 – Profil émotionnel NRC par catégorie

4.6 Nuages de mots

Les nuages de mots constituent une représentation visuelle synthétique du vocabulaire dominant par catégorie. La taille de chaque mot est proportionnelle à sa fréquence d'apparition dans les messages de la catégorie concernée.

Ces visualisations confirment visuellement les observations de l'analyse linguistique : chaque catégorie possède une signature lexicale distinctive, avec des termes spécifiques qui s'imposent immédiatement à la lecture du nuage.

Haineux



Non-Haineux

FIGURE 4.6 – Nuage de mots

4.7 Ce que l'analyse exploratoire des données nous a appris

L'analyse exploratoire a débouché sur plusieurs conclusions qui ont directement orienté nos choix de modélisation :

1. **La tâche binaire est pertinente et faisable.** Les messages haineux et non haineux présentent des caractéristiques linguistiques, stylistiques et émotionnelles suffisamment distinctes pour qu'un modèle puisse les séparer avec une bonne fiabilité.
2. **La tâche multi-classes est plus complexe.** Certaines catégories partagent un vocabulaire commun (notamment racisme et xénophobie), ce qui rendra la classification fine plus difficile et nécessitera des modèles plus puissants.
3. **La vectorisation TF-IDF est adaptée.** Le vocabulaire discriminant identifié dans l'EDA est précisément le type d'information que TF-IDF capture : les termes fréquents dans une catégorie mais rares dans les autres recevront un poids élevé, facilitant la distinction entre classes.
4. **Un modèle pré-entraîné sur la haine sera utile.** La richesse sémantique et émotionnelle des messages haineux suggère qu'un modèle comme Toxic BERT, pré-entraîné spécifiquement sur des données toxiques, pourra capturer des nuances inaccessibles aux modèles classiques.
5. **Les faux positifs seront un défi.** Certains messages non haineux contiennent des termes appartenant au vocabulaire haineux dans un contexte neutre (citations, témoignages, analyses). L'analyse exploratoire nous a sensibilisés à ce risque que nous retrouverons dans l'analyse des limites des modèles.

Chapitre 5

Modélisation Machine Learning

5.1 Stratégie de modélisation, pourquoi cette progression ?

Notre stratégie de modélisation repose sur une progression délibérée : partir du modèle le plus simple et le plus interprétable, puis complexifier progressivement pour mesurer le gain réel apporté par chaque nouvelle approche. Cette démarche nous permet de justifier chaque choix : si un modèle simple suffit, il n'est pas nécessaire d'en utiliser un complexe.

Les cinq modèles retenus suivent cette logique :

1. **Régression Logistique** : modèle linéaire de référence
2. **TF-IDF + Régression Logistique** : vectorisation pondérée
3. **Bag of Words + Régression Logistique** : vectorisation par fréquence
4. **Random Forest** : modèle ensembliste non linéaire
5. **Toxic BERT** : modèle de deep learning pré-entraîné

Pour chaque modèle, nous évaluons deux tâches :

- **Tâche binaire** : détecter si un message est haineux ou non haineux, premier filtre automatique
- **Tâche multi-classes** : identifier la catégorie de harcèlement parmi les six, classification fine

Protocole d'évaluation

Tous les modèles sont entraînés sur **Base_Train2.csv** (2 400 messages) et évalués sur **Base_Test2.csv** (240 messages jamais vus pendant l'entraînement). Les métriques utilisées sont : l'accuracy, la précision, le rappel et le **F1-score** (moyenne harmonique précision/rappel) qui constitue notre métrique principale car il équilibre les deux aspects de la détection.

5.2 Modèle 1 — Régression Logistique

5.2.1 Justification du choix

L'analyse exploratoire avait montré que les messages haineux et neutres présentent des vocabulaires très distincts : les nuages de mots révélaient des termes spécifiques à chaque classe. Cette séparation nette dans l'espace lexical justifie un modèle linéaire : si les classes sont bien séparables, un modèle simple suffit.

La régression logistique est combinée avec une vectorisation TF-IDF qui transforme chaque message en vecteur numérique pondéré. TF-IDF attribue un poids élevé aux mots rares mais discriminants, et un poids faible aux mots banals présents dans tous les messages.

5.2.2 Paramètres du modèle

Paramètre	Valeur
Vectorisation	TF-IDF (unigrammes + bigrammes)
Stop words	Anglais (nltk)
max_iter	3 000
class_weight	balanced
Validation	Croisée 5-folds (StratifiedKFold)

5.2.3 Résultats

Évaluation	Tâche binaire	Tâche multi-classes
Validation croisée (F1 moyen)	—	0.90
Validation 20%	91%	91%
Test final (Base Test)	89%	91%

Les performances sont stables sur les trois évaluations : le modèle généralise bien et n'a pas mémorisé les données d'entraînement. Par catégorie, le Validisme (F1 : 0.97) et l'Homophobie (F1 : 0.95) sont les mieux détectés grâce à leur vocabulaire très exclusif. Le Racisme (F1 : 0.78) est plus difficile car il partage du vocabulaire avec la Xénophobie — un résultat que nos nuages de mots avaient anticipé.

5.3 Modèle 2 — TF-IDF + Régression Logistique

5.3.1 Justification du choix

L'analyse exploratoire des données avait montré que certains mots sont très discriminants selon la catégorie : *muslims* apparaît massivement en Islamophobie, *disabled* en Validisme, *immigrants* en Xénophobie. TF-IDF exploite précisément ce signal : il donne plus de poids aux mots rares mais informatifs, et moins de poids aux mots banals présents partout. Contrairement au Bag of Words qui compte simplement les occurrences, TF-IDF pondère chaque mot selon sa fréquence dans le message et sa rareté dans tout le corpus.

5.3.2 Paramètres du modèle

Paramètre	Valeur
Vectorisation	TF-IDF (unigrammes + bigrammes)
max_features	5 000
Stop words	Anglais
max_iter	1 000
random_state	42

5.3.3 Résultats

Deux expériences ont été menées pour vérifier la robustesse du modèle :

Expérience 1 — Base Test indépendante :

Tâche	Accuracy	Observation
Binaire	89%	Precision Haineux : 0.93 / Recall : 0.85
Multi-classes	88%	Validisme 0.97, Xénophobie 0.97, Racisme 0.71

Expérience 2 — Stabilité sur 3 découpages :

Tour	Binaire	Multi-classes
Tour 1 (seed=42)	98%	93%
Tour 2 (seed=1)	97%	90%
Tour 3 (seed=123)	96%	90%
Moyenne	97.36%	91.18%

La faible variance entre les trois tours confirme que le modèle apprend des patterns généralisables. La différence entre les scores internes (97%) et le score sur Base Test indépendante (89%) est normale : Base_Test2 a été construite séparément depuis le début, ce qui en fait un test plus difficile et plus représentatif des performances réelles.

5.4 Modèle 3 — Bag of Words + Régression Logistique

5.4.1 Justification du choix

Le Bag of Words constitue le modèle de référence (*baseline*) de notre projet : simple, rapide et interprétable. Si ce modèle basique obtient déjà de bonnes performances, cela confirme que le signal textuel est suffisamment fort pour être exploité sans pondération sophistiquée. Son résultat sert de plancher : tout modèle plus complexe doit faire mieux pour justifier sa complexité.

5.4.2 Démarche d'entraînement progressif

Le modèle a été entraîné en 6 versions successives, chacune ajoutant une amélioration :

Version	Amélioration	Accuracy (CV)
V1	BoW basique	baseline
V2	+ Suppression stop words	+ légère amélioration
V3	+ Limitation vocabulaire (3 000 mots)	stable
V4	+ Bigrammes (paires de mots)	amélioration notable
V5	+ min_df=2 (mots apparaissant ≥ 2 fois)	stable
V6	+ Régularisation ajustée (C=5)	meilleure version

5.4.3 Résultats

Tâche	Accuracy	Observation
Binaire	87.92%	Recall neutres : 97% / Recall haineux : 79%
Multi-classes	90%	Validisme : F1 1.00 / Racisme : plus difficile

Le modèle est meilleur pour détecter les messages neutres que les messages haineux. Les messages haineux ratés correspondent aux cas de *haine froide* : des messages qui évitent les insultes directes et s'expriment de façon rhétorique, sans vocabulaire explicitement haineux — un pattern que nos visualisations avaient identifié.

Un test de Prompt Engineering a également été mené : 6 messages de la Base Test ont été soumis manuellement à ChatGPT avec un prompt structuré, et les résultats ont été comparés aux prédictions du modèle BoW. Cet exercice a permis de mesurer la valeur ajoutée d'un modèle entraîné sur nos données spécifiques face à un modèle généraliste.

5.5 Modèle 4 — Random Forest

5.5.1 Justification du choix

L'analyse exploratoire des données avait identifié deux limites des modèles linéaires : la haine implicite (sans vocabulaire explicite) et les catégories au vocabulaire ambigu (Sexisme, Racisme). Le Random Forest répond à ces défis : en créant plusieurs centaines d'arbres de décision, chacun entraîné sur un sous-échantillon différent, il peut capturer des *combinaisons* de mots ; un message peut être classé haineux non pas à cause d'un seul mot mais à cause de la présence simultanée de plusieurs indices textuels.

5.5.2 Paramètres du modèle

Paramètre	Valeur
Nombre d'arbres (n_estimators)	optimisé par recherche
Vectorisation	TF-IDF
Sélection	meilleure configuration par F1

5.5.3 Résultats

Tâche	Accuracy	Observation
Binaire	88%	Recall neutres : 93% / Recall haineux : 82%
Multi-classes	88%	Validisme 0.97, Xénophobie 0.97

Les performances du Random Forest sont comparables au Bag of Words, ce qui suggère que le signal textuel de notre corpus est majoritairement linéaire. Les modèles ensemblistes n’apportent pas de gain significatif sur ces données. Les mêmes cas difficiles persistent : haine froide et catégories au vocabulaire ambigu.

5.6 Modèle 5 — Toxic BERT

5.6.1 Justification du choix

Tous les modèles précédents analysent les mots individuellement sans comprendre le sens de la phrase. Or, l’analyse exploratoire des données avait identifié une limite claire : les messages à haine froide, qui évitent les insultes directes et s’expriment de façon rhétorique, passaient régulièrement inaperçus. Un message comme “*Why do these people always behave like that ?*” n’a aucun mot explicitement haineux mais est clairement discriminant dans son contexte.

BERT (*Bidirectional Encoder Representations from Transformers*) résout ce problème : il comprend le contexte, le sens implicite et les relations entre les mots dans une phrase. **Toxic BERT** est une version de BERT pré-entraînée spécifiquement sur des données toxiques, ce qui lui confère une sensibilité particulière aux formulations haineuses même implicites.

Approche	Capacité
BoW / TF-IDF / Random Forest	Mots individuels
Toxic BERT	Contexte, sens implicite, relations entre mots

5.6.2 Résultats

Tâche	Accuracy	F1
Binaire	94%	0.94
Multi-classes	91%	0.91

Toxic BERT obtient la meilleure performance en tâche binaire parmi tous nos modèles. L’Homophobie et la Xénophobie restent les mieux détectées : même BERT bénéficie des marqueurs lexicaux forts identifiés dans l’analyse exploratoire des données. Le Sexisme et le Racisme restent les plus difficiles, ce qui confirme que la difficulté vient de la nature intrinsèquement ambiguë de ces discours, et non d’un manque de puissance du modèle.

5.7 Comparaison des modèles, tableau récapitulatif

Modèle	Bin.	Multi.	Homo.	Islam.	Racisme	Sexisme	Valid.	Xéno.
Rég. Logistique	89%	91%	0.95	0.86	0.78	—	0.97	—
TF-IDF	89%	88%	0.95	0.86	0.71	0.71	0.97	0.97
Bag of Words	88%	90%	—	—	—	—	1.00	—
Random Forest	88%	88%	0.95	0.89	0.78	0.77	0.97	0.97
Toxic BERT	94%	91%	0.87	0.85	—	0.74	0.80	0.85

TABLE 5.1 – Comparaison des performances des cinq modèles

Lecture du tableau :

- **Tâche binaire** : Toxic BERT domine avec 94%, suivi de TF-IDF et Régression Logistique (89%), puis Random Forest et Bag of Words (88%).
- **Tâche multi-classes** : les performances se resserrent autour de 88–91% pour tous les modèles. TF-IDF et Régression Logistique atteignent 91%, comme Toxic BERT.
- **Validisme** : catégorie la mieux reconnue par tous les modèles ; le Bag of Words atteint même 100% de F1 grâce à son vocabulaire très exclusif.
- **Racisme et Sexisme** : catégories les plus difficiles pour tous les modèles, exactement comme prédit par l’analyse exploratoire des données.

5.8 Limites identifiées

Limites communes à tous les modèles

- **Haine implicite et sarcasme** : les messages qui évitent les insultes directes et s'expriment de façon rhétorique passent régulièrement inaperçus
- **Faux positifs** : des messages neutres contenant des termes issus du vocabulaire haineux dans un contexte neutre (citations, analyses, témoignages) peuvent être mal classés
- **Racisme et Sexisme** : ces catégories partagent du vocabulaire avec d'autres classes, rendant leur classification plus incertaine
- **Généralisation** : les modèles sont entraînés sur des données en anglais ; leurs performances sur d'autres langues ou registres ne sont pas garanties

Ces limites ne remettent pas en cause la validité de l'approche : elles sont inhérentes à la nature du langage haineux, qui évolue constamment pour contourner les systèmes de détection. Elles constituent autant de pistes d'amélioration pour les travaux futurs.

Chapitre 6

Application web : SafeText

6.1 Objectifs et conception

Le site web SafeText constitue la vitrine interactive de notre projet : il rend nos modèles de machine learning accessibles à tous, sans aucune connaissance technique requise. L'objectif est double : démontrer concrètement les capacités de nos modèles via une interface intuitive, et proposer des fonctionnalités originales qui vont au-delà de la simple prédiction.

La conception du site a débuté par une réflexion préalable : à partir des personas définis en amont (Léa, internaute victime, et Thomas, modérateur professionnel), nous avons identifié deux besoins distincts : une interface simple pour l'utilisateur lambda, et une interface analytique pour le professionnel. Ces deux profils ont orienté l'ensemble des choix fonctionnels et visuels du site.

Accès au site

- **URL** : <http://217.160.27.219>
- **Hébergeur** : IONOS VPS
- **Stack technique** : PHP, Python, CSS, MySQL

6.2 Fonctionnalités développées

Le site SafeText propose six fonctionnalités principales, organisées en pages distinctes :

6.2.1 Page d'accueil — `index.php`

La page d'accueil présente le projet SafeText, son contexte et ses objectifs. Elle sert de point d'entrée et oriente l'utilisateur vers les différentes fonctionnalités du site. Elle intègre également les visualisations clés issues de notre analyse exploratoire, permettant à l'utilisateur de comprendre les données sur lesquelles nos modèles ont été entraînés.

6.2.2 Prédiction — `predict.py`

La fonctionnalité centrale du site : un formulaire permet à l'utilisateur de saisir n'importe quel message texte. Le script Python charge le modèle sauvegardé au format `.pkl` et retourne :

- La classification binaire : le message est-il haineux ou non ?
- Si haineux, la catégorie identifiée parmi les six formes de harcèlement
- Le modèle utilisé pour la prédiction

Les prédictions sont effectuées en temps réel sans réentraînement : les modèles sont chargés depuis les fichiers `.pkl` compilés préalablement.

6.2.3 Comparaison des modèles — `comparer.py`

Une fonctionnalité originale qui permet de soumettre un message et de voir simultanément les prédictions de **tous les modèles** côte à côte. L'utilisateur peut ainsi comparer les résultats de la Régression Logistique, TF-IDF, Bag of Words, Random Forest et Toxic BERT sur un même message et observer les divergences entre approches classiques et deep learning.

6.2.4 Traducteur — `traducteur.py`

Une fonctionnalité de traduction bienveillante a été intégrée : le message haineux saisi est transformée en message bienveillant et positif.

6.2.5 Page Prévention — `prevention.php`

Une page informative présentant les six formes de harcèlement couvertes par le projet : définitions, exemples et ressources pour les victimes. Cette page répond directement au besoin de Léa (persona 1) : comprendre si ce qu'elle vit constitue réellement du harcèlement.

6.2.6 Quiz — `quiz.php`

Un quiz interactif permettant aux utilisateurs de tester leurs connaissances sur le harcèlement en ligne. Cette fonctionnalité ludique et pédagogique vise à sensibiliser le grand public aux différentes formes de discours haineux, en s'appuyant sur des cas concrets issus de notre base de données.

6.2.7 Espace compte — `compte.php`

Un système d'authentification complet (inscription et connexion) permet aux utilisateurs de créer un compte personnel. Cet espace leur permet de conserver un historique de leurs analyses et de retrouver leurs prédictions précédentes.

6.3 Architecture technique

6.3.1 Stack technologique

Composant	Technologie	Rôle
Frontend	PHP, HTML, CSS	Interface utilisateur
Backend	Python (Flask)	Appels aux modèles ML
Base de données	MySQL	Comptes utilisateurs
Modèles ML	Pickle (.pkl)	Prédictions en temps réel
Hébergement	IONOS VPS	Mise en ligne

6.3.2 Intégration des modèles .pkl

L'intégration des modèles dans le site repose sur le format `pickle` de Python : chaque modèle entraîné dans le notebook est sérialisé via `joblib` et sauvegardé sous forme de fichier `.pkl`. Lors d'une requête utilisateur, le script Python charge le fichier correspondant et effectue la prédiction sans réentraînement.

Onz fichiers `.pkl` sont ainsi intégrés au site ainsi que 5 fichiers respectifs pour Toxic Bert binaire ainsi que multi-classe.

6.3.3 Déploiement sur IONOS

Le site a été déployé sur un VPS IONOS, compatible PHP et Python et adapté aux contraintes d'un projet étudiant. Le déploiement a nécessité la configuration du serveur, l'installation des dépendances Python (scikit-learn, transformers, joblib) et la mise en place de la base de données MySQL pour la gestion des comptes utilisateurs.




FIGURE 6.1 – Page principale d'analyse




FIGURE 6.2 – Jauge de toxicité et comparaison des modèles




FIGURE 6.3 – Traducteur de bienveillance




FIGURE 6.4 – Quiz




FIGURE 6.5 – Compte utilisateur et historique

6.4 Visualisations intégrées au site

Conformément aux attentes du projet, le site intègre les visualisations les plus pertinentes issues de notre analyse exploratoire : distribution des classes, nuages de mots par catégorie et comparaison des performances des modèles. Ces graphiques permettent à l'utilisateur de comprendre sur quelles données les modèles ont été entraînés et d'interpréter les prédictions dans leur contexte.

Chapitre 7

Conclusion

7.1 Bilan du projet

SafeText est parti d'une question simple : peut-on détecter automatiquement un message haineux et identifier sa forme ? Au terme de huit semaines de travail, la réponse est un oui avec des performances solides et une application web déployée et accessible à tous.

Nous avons accompli l'ensemble des objectifs fixés en début de projet :

- **Constitution d'une base de données équilibrée** : 2 640 messages annotés, répartis équitablement entre six catégories de harcèlement et des messages neutres, issus de deux sources Kaggle complémentaires.
- **Analyse exploratoire approfondie** : distribution des classes, analyse linguistique, stylistique et émotionnelle (lexique NRC), nuages de mots, chaque visualisation a orienté une décision concrète sur la modélisation.
- **Cinq modèles de machine learning entraînés et comparés** : de la Régression Logistique au Toxic BERT, en passant par TF-IDF, Bag of Words et Random Forest ; couvrant le spectre des approches classiques et deep learning.
- **Performances solides** : jusqu'à 94% en tâche binaire (Toxic BERT) et 91% en multi-classes (TF-IDF, Régression Logistique, BERT) sur des données jamais vues pendant l'entraînement.
- **Application web déployée** : six fonctionnalités dont une prédiction en temps réel, un comparateur de modèles, un traducteur automatique, un quiz pédagogique et un espace compte personnel.

Ce qui nous rend fiers

Le fait que même notre modèle le plus simple Bag of Words à 88% obtienne de bonnes performances confirme que notre travail de constitution et d'équilibrage des données était de qualité. Un bon modèle commence toujours par de bonnes données.

7.2 Limites et pistes d'amélioration

Malgré ces résultats encourageants, plusieurs limites ont été identifiées tout au long du projet :

- **La haine implicite reste difficile à détecter.** Les messages rhétoriques, sarcastiques ou formulés sans vocabulaire explicitement haineux échappent encore régulièrement à nos modèles. C'est une limite inhérente à la nature évolutive du langage haineux, qui s'adapte constamment pour contourner les systèmes de détection.
- **Le Racisme et le Sexisme restent les catégories les moins bien classées.** Ces deux formes de harcèlement partagent du vocabulaire avec d'autres catégories et s'expriment souvent de façon plus ambiguë que l'Homophobie ou le Validisme. Davantage de données annotées sur ces catégories spécifiques permettrait d'améliorer les performances.
- **Les données sont uniquement en anglais.** Nos modèles n'ont été entraînés que sur des corpus anglophones. Leurs performances sur des messages en français ou dans d'autres langues ne sont pas garanties sans un réentraînement spécifique.
- **La taille de la base reste limitée.** Avec 2 640 messages au total, notre corpus est suffisant pour un projet universitaire mais modeste par rapport aux standards industriels. Des modèles entraînés sur des millions de messages seraient significativement plus robustes.

Parmi les pistes d'amélioration envisageables :

1. Enrichir la base de données avec des messages en français et dans d'autres langues
2. Affiner Toxic BERT spécifiquement sur les catégories Racisme et Sexisme
3. Mettre en place un système hybride : TF-IDF comme premier filtre rapide, BERT en second niveau pour les cas ambigus
4. Intégrer une fonctionnalité d'explication des prédictions (*explainability*) : afficher les mots qui ont le plus contribué à la décision du modèle
5. Collecter des retours utilisateurs via le site pour améliorer les modèles en continu

7.3 Ce que le projet nous a apporté

Au-delà des résultats techniques, ce projet nous a permis de vivre de bout en bout le cycle complet d'un projet de science des données : de la question de recherche jusqu'au déploiement en production, en passant par la collecte des données, leur exploration, la modélisation et le développement web. Le module gestion de projet, vu au semestre cinq, nous a donné une bonne base pour ce projet, notamment pour GitHub, ainsi que les personas, le Backlog et la maquette.

Nous avons appris à :

- Travailler en équipe avec Git sur un projet technique commun, en gérant les conflits de version et en maintenant un dépôt propre et structuré
- Prendre des décisions méthodologiques et les justifier : pourquoi ce modèle ? Pourquoi ces métriques ? Pourquoi cet équilibre ?
- Faire face aux erreurs et les corriger : la confusion initiale sur la base train/test nous a appris que la rigueur méthodologique n'est pas optionnelle en science des données
- Communiquer nos résultats de façon claire et accessible, à travers le site web, les visualisations et ce rapport

Le sujet du harcèlement en ligne nous a également sensibilisés à une réalité sociale préoccupante. Construire un outil capable d'identifier et de nommer ces formes de violence verbale (même imparfaitement) c'est contribuer, à notre échelle, à les rendre visibles.

Liens du projet

- **Site web** : <http://217.160.27.219>
- **GitHub** : <https://github.com/hafsaac/Harcelement>
- **Lien vidéo** : https://youtu.be/g_RdN-bG95w

Merci à Sandra Bringay, Namrata Patel et Théodore Michel-Picqué pour nous avoir guidés sans jamais nous tenir la main, c'est ce qui nous a le plus appris.